

KRONOS

Crypto 量化改进研究 与工程路线

研究价值 · 工程难度 · 实施方法 · 验证规范

从增量表征验证出发，而不是从复杂架构出发。

先改决策目标，再改变 token 语义；先证明一个模块有用，再组合多个模块。

01 最小可验证方案

冻结 Kronos-small，建立普通特征与动量参与度对照。

02 条件式升级路线

按证据引入状态数据、继续训练、事件时间和符号搜索。

03 可审计实验系统

固定数据、权重、时序与成本，保留失败试验和停止条件。

版本 1.0 / 2026 年 10 月 7 日

适用范围：研究原型、实验设计与开发规划

本文未实际训练模型或验证交易收益。

阅读导航

先阅读第 01—04 章确定研究边界；开发时结合第 14—16 章及附录 A。各路线独立成章，可按优先级跳读。

01 研究定位与结论	3
02 Kronos 的事实基线与需要纠正的前提	4
03 难度、成本与优先级总览	5
04 统一研究问题与最小实验系统	6
05 冻结表征与量化瓶颈诊断	7
06 动量、净收益与策略参与度改造	9
07 波动、下行风险与预测分布	11
08 Crypto 原生状态：先做后融合	12
09 Crypto 继续训练与成交密度加权	13
10 横截面排序与组合层	15
11 事件时间与双时钟：为什么应当后置	16
12 输入重编码、tokenizer 重建与从头训练	17
13 神经一符号：受限策略接口，而非无限因子工厂	18
14 数据、时间切分与验证规范	19
15 工程分层、资源预算与 Freqtrade 接入	21
16 分阶段执行、晋级与停止条件	23
附录 A 接口、配置与审计模板	25
附录 B 术语与解释边界	27
参考资料与核验范围	28

阅读标记：[01] 等编号可跳转至参考资料。难度评分和实施顺序属于工程判断；数据与代码事实按文末来源核验。

01 研究定位与结论

1.1 这份文档要解决什么问题

本方案面向一个具体问题：在 crypto 因子收益弱、交易成本显著、市场状态不断变化的前提下，Kronos 是否仍值得研究，以及怎样用有限工程投入判断它有没有增量价值。目标不是拼出功能最多的金融 AI 系统，而是建立一条可以逐步接受或否定假设的研究路线。

推荐的第一版：原 tokenizer + 冻结 Kronos-small 表征 + 一个预先固定的动量基线 + 简单读出器 / 参与度预测头。 有可靠历史数据时，再加入少量 OI、funding、basis 等外部状态。暂不重做 tokenizer，不先建设双时钟生成模型，也不立即开展大规模符号搜索。

本方案把三类成果分开：预测贡献是相同信息条件下提高预测能力；经济贡献是风险与成本可比时改善样本外组合表现；工程贡献是降低计算成本、提高可复现性和可审计性。三者都可能有价值，但不能互相替代。

1.2 四项核心判断

先证明预训练有用，再扩大训练。 最先比较普通特征模型与加入 Kronos 表征后的同类模型，而不是直接比较不同复杂度的完整策略。一个没有 Kronos 的小模型达到同样效果，应当视为减少成本的成功结论。

先改目标，再改输入语言。 让已有表征预测固定持有期净收益、动量参与价值或风险，比同时更改输入通道、tokenizer、时钟和损失更容易归因。改动少不是理论上更优，而是更便于发现失败发生在哪一层。

先增加可信信息，再增加模型自由度。 外部状态可能扩大可用信息集；成交密度加权主要改变模型如何分配拟合资源；事件条改变时间表达；符号搜索改变策略假设空间。这四件事不可混为一谈。

验证体系是第一项工程，不是最后一道包装。 所有模块必须共享时间切分、信息可用时间、交易成本和试验登记。否则，一个更强的搜索器也可能只是更高效地寻找历史偶然性。[15]

1.3 边界与不确定性

本文提供的是研究设计和工程估计，没有实际训练模型，没有访问或运行用户服务器，也没有完成任何实盘收益验证。难度评分不是成功概率；后文的配置数值、样本规模和验收示例均为建议起点，不是已经调优的参数。

沿用此前讨论中的开发条件：Python / PyTorch 能力、现有 Freqtrade 工作目录 `/home/athena/ft_userdata`，以及 RTX 4060 Laptop。资源规划按约 8GB 显存假设展开，实施前须核实实际显存、驱动和可用内存。本方案不修改该目录，只把它作为未来接入位置。

核心决策原则：优先做“成本低、结论清楚、失败也能提供信息”的实验，而不是优先做“名字新、结构复杂、看起来有论文感”的实验。

02 Kronos 的事实基线与需要纠正的前提

2.1 原模型提供了什么

Kronos 使用 OHLCVA 六通道：开、高、低、收、成交量、成交额。tokenizer 将连续序列编码为粗／细两部分离散 token；自回归 Transformer 学习其转移关系。本文把它看作可复用的历史序列表征和生成骨干，而不把它直接视为交易策略。[01][02]

代码中的 `Kronos.decode_s1()` 同时返回 logits 和 `context`，后者可以直接用作历史表征。提取表征无需生成未来路径。`KronosPredictor` 则封装了标准化、时间特征、生成和反标准化。原时间嵌入包括分钟、小时、星期、日和月，不直接提供事件持续时间这一变量。[03][04]

模型	参数量	上下文长度	本方案中的位置
Kronos-mini	4.1M	2048	资源敏感的独立对照，注意 tokenizer 不同
Kronos-small	24.7M	512	第一阶段默认骨干
Kronos-base	102.3M	512	small 有增益后才做容量对照
Kronos-large	499.2M	512	当前公开模型卡未提供权重，不作为依赖

模型规格以核验时的官方模型卡为准。mini 与 small 的比较不只是参数大小对照，因为 tokenizer 和上下文设置也不同。[09]

2.2 五项重要修正

不是第一次接触 crypto。 论文数据表包含约 12.37 亿条 Binance 记录，涵盖 crypto／永续合约；训练还提高了 crypto 等类别的抽样权重。因此，crypto 继续训练是分布与任务适配，不是让模型首次认识这一市场。[01]

不是完全未处理价格尺度。 原实现对输入窗口的各通道做标准化并截断。收益率重编码仍可研究，但不能以“原模型只会记名义价格”作为已经成立的解释。[03]

论文写过训练截止日期和成本。 完整版称预训练数据截至 2024 年 6 月、测试始于 7 月；投资模拟写明每笔交易成本 0.15%。仍需区分论文版本、公开权重和具体 checkpoint 的来源关系，不能把三者自动等同。[01][08]

RankIC 不能一概称为横截面选币能力。 论文的价格序列指标是在单个预测样本的未来路径内计算；收益预测指标另有定义。投资模拟确实做了 A 股组合排序，但这不证明 crypto 横截面任务天然更容易。[01]

归一化修复不等于已经证实论文失效。 PR #234 修复的是公开微调数据管线使用未来窗口统计量的问题。它要求重新审计相关实验，但不能单凭这个补丁断言全部预训练权重或论文结果均被污染。[07]

2.3 本文引用的代码快照

核验日期为 2026-10-07，仓库默认分支当时指向 `67b630e67f6a18c9e9be918d9b4337c960db1e9a`。代码建议依据这个快照，而不是依据未合并社区 PR。实施时同时固定仓库提交、tokenizer revision、模型 revision 和本地文件校验值。[02]

本文不把社区收益截图、个别失败回测或模型热度用作收益能力证据。它们最多帮助发现值得审计的问题。

03 难度、成本与优先级总览

3.1 评分口径

工程难度按 1—5 级估计：1 为局部接口／损失改动；2 为一个清晰模块；3 为数据、训练与回测的协同修改；4 为多模块重构；5 为新的研究基础设施或模型体系。数据难度单独列出，因为可靠历史状态数据可能比模型开发更昂贵。

算力等级表示相对于其他路线的负担，不等于指定 GPU 能否运行。验证难度表示区分真实增益和噪声的困难程度。所有评分都是本方案的工程判断，而非客观测量结果。

路线	工程	数据	算力	验证	优先级
冻结表征与预测探针	1-2	2	1-2	4	P0
动量参与／净收益头	2；解冻后 3	2	1-3	5	P0
量化前后信息诊断	2-3	2	2	4	P1
波动、下行风险头	2-3	2	2	4	P1
原生状态后融合	2	2-4	1-2	4	P1，数据可靠时
固定 tokenizer 的继续训练	2-3	3	3	4	P2
成交活跃度加权	2	2	增量低	4	P2，小型消融
横截面排序	3	3-4	2-3	4-5	P2，替代分支
历史事件条辅助输入	3-4	4	2-3	4	P3
完整事件时间／双时钟生成	4-5	4-5	4	5	P4
重编码与 tokenizer 重建	4	3	4	5	P4，有诊断证据后
从头训练 crypto Kronos	4-5	4-5	5	5	独立架构研究
受限符号规则／完整自动搜索	2-3／4-5	2-4	可变	5	P3／P4

3.2 不应按“从上到下全做”理解

P0 是共同起点；后续是条件分支。表征有增益但任务不匹配，可继续研究预测头。状态数据有增益而 Kronos 无增益，可以保留数据模块、删除骨干。量化前有信息、量化后没有，才进一步研究 tokenizer。事件时间在统一任务上有增益，才考虑双时钟。

建议先设定一个有限实验预算。示例是最多三种读出器、两个预先指定的标签、少数随机种子；数值可以调整，但必须在观察结果前记录。反复追加配置本身也属于搜索，应计入试验总量。

3.3 资源投入应当如何估算

先用小批量测量峰值显存、每秒窗口数、数据读取占比和缓存体积，再推算全实验成本。不要根据参数量直接承诺训练天数；激活、上下文长度、精度、tokenizer 前向和数据管线都可能成为瓶颈。

冻结骨干时，预先提取末端表征通常比每轮训练重复运行骨干节省资源。但缓存的可复用范围取决于 checkpoint、窗口定义和标准化，不能为了速度混用不同折的特征。第 14 章给出缓存约束。

04 统一研究问题与最小实验系统

4.1 先固定问题，而不是固定复杂架构

第一轮选择一个交易场景、一种基本频率、一个主要预测持有期和一套历史币种池规则。作为工程起点，可使用固定时间条和固定持有期；这只是控制变量，不代表它们最赚钱。

明确信号在何时可用、何时最早成交。若输入包含某根 k 线的收盘价与最终成交量，就必须等该根完成并收到数据后才能产生信号。回测不能同时假定以已经知道的同一收盘价无延迟成交。

4.2 最小系统的职责分离

建议系统分为数据快照、因果特征、Kronos 编码器、读出器、策略规则、成本与组合回测、实验登记七个模块。第一版策略规则固定，模型主要回答一个窄问题。这样可以分别替换编码器或预测头，而不改变执行逻辑。

$$z_t=f_{\theta}\left(X_{\leq t}\right), \hat{y}_t=g_{\phi}\left(b_t, z_t, q_t\right)$$

其中 b 为普通价量特征，q 为可选外部状态。数据不可得时 q 分支应关闭，而不是用不可信补值假装齐全。

4.3 一套必须保留的基线

编号	模型／规则	主要回答的问题
B0	不交易、简单持有、固定动量规则	策略是否只是市场暴露或参数选择
B1	普通特征 + 正则化线性读出器	低成本信息是否已足够
B2	普通特征 + 小型非线性模型	是否只需简单非线性
B3	普通特征 + Kronos 表征 + 同类读出器	Kronos 是否提供增量
B4	随机冻结骨干 + 同类读出器	预训练是否优于随机高维展开
B5	资源可比的小型时序模型	是否真正需要这个骨干

B4 保留原 tokenizer 时，只检验自回归骨干预训练的价值；并没有消除 tokenizer 的预训练信息。随机骨干同样可能保留部分输入结构，因此它是消融对照，不是“完全无信息”的对照。

同一实验中尽量保持币种池、目标、时间切分、特征时点、预测头容量和调参预算一致。预训练模型有不同历史数据来源，报告时应说明，不能把“相同输入字段”写成完全相同的数据预算。

05 冻结表征与量化瓶颈诊断

5.1 为什么这是第一项实验

冻结骨干可直接检验预训练是否把价量历史组织成更容易读取的表示。它绕开多步生成、采样温度和路径均值问题；失败时也能帮助判断是否值得继续训练。工程难度 1-2/5，主要负担在特征缓存与公平验证。

实现入口是 `decode_s1()` 返回的 `context`。最小读出取最后一个有效历史位置，而非把整段输出直接当作不同历史时点的实时特征。[03]

5.2 实施步骤

第一步：固定 checkpoint 和输入契约。 记录 OHLCVA 通道顺序、上下文长度、时区、窗口边界、缺失处理、截断值和标准化版本。成交额优先使用可信原始字段；近似生成时必须标注来源。

第二步：以决策时点为单位生成窗口。 只使用该时点已知的历史，按与推理一致的方法标准化。将 tokenizer 和主干明确设为评估模式，关闭梯度，提取末端表征。

第三步：先做单一读出，再做有限升级。 从 Ridge/带正则化的线性分类器开始；不足时再尝试小 MLP 或树模型。降维、缩放、缺失填补均仅在训练折拟合，不得先在全数据上训练 PCA。

第四步：比较“普通特征”与“普通特征 + 表征”。 只比较表征模型和随机猜测是不够的。Kronos 可能仅仅重新编码了波动或动量，必须检查它是否超越已经显式提供的这些信息。

5.3 最容易被忽略的缓存问题

窗口标准化会使同一根历史 K 线在不同预测窗口中获得不同数值，因而其 token/hidden state 也可能不同。不能将全历史只编码一次，然后把每个位置的 hidden state 都当成当时可得的实时特征。

正确做法是按固定预测原点计算，或者设计并验证一个严格等价的增量方案。缓存键至少包含数据快照、资产、窗口起止、标准化版本、tokenizer 与模型 revision、数值精度。骨干解冻或换 checkpoint 后，旧表征缓存失效。

5.4 量化前后诊断：什么时候值得重做 tokenizer

可在相同窗口和训练折中读取四类表示：普通价量特征、量化前连续表示、量化后表示、主干末端表示。tokenizer 的连续编码与量化步骤在源码中是独立阶段，因此可以增加诊断接口，而不必先重建模型。^[03] 比较时应控制读出器自由度：维度差异很大时，可分别使用一致正则化预算，或仅在训练折拟合统一维度的投影。不能把一个高容量头的收益归因于表示本身。

观察结果	合理解释	下一步
连续、离散、主干均无稳定增益	当前信息、目标或样本不足	停止扩模，审计数据和任务
连续优于离散	量化可能丢掉相关细节	重复验证后研究 tokenizer
离散优于连续	量化可能有去噪价值	保留 tokenizer
主干优于离散直接读出	序列预训练可能有贡献	研究任务头和有限解冻
只在单折或单币种有效	偶然性或高度局部适配	不升级为普遍结论

这些解释都是候选解释，不是由一次结果自动推出的因果结论。线性探针失败也不证明“完全无信息”，只是说明当前简单读出方式未能利用它。

5.5 验收与停止条件

验收应看配对样本外差异：相同时间区间内，加入表征后预测损失和净组合表现是否有经济上有意义的改善，是否依赖极少数窗口。若有限的非线性读出和受控解冻均无增益，应停止无限增加头部容量。输出物包括可复现的特征缓存、各基线预测、每折指标、成本敏感性、表征提取配置和失败试验记录。探针成功只是进入下一阶段的证据，不是实盘许可。

06 动量、净收益与策略参与度改造

6.1 将“改成动量设计”拆成三个层级

第一层是保留全部输入，只增加多尺度动量等基线特征；第二层是保留 tokenizer，改变下游标签和决策目标；第三层才是把输入改成收益率／形态语言并重建 tokenizer。优先做第二层，避免把低成本任务适配升级成高成本表示重建。

已有 Deep Momentum Networks 研究将趋势估计、仓位和交易成本放入学习框架，说明这一研究方向有先例；但那不是 Kronos 在 crypto 上有效的证明，也不是本方案门控设计的直接实证支持。[\[10\]](#)

6.2 推荐第一版：参与，不自由反转

先固定基础动量仓位，再让模型输出参与程度：

$$w_t = a_t w_t^{mom}, 0 \leq a_t \leq 1$$

a 可以先取“参与／跳过”，再扩展为连续缩放。第一版不让模型任意把动量改成反向交易。这样限制了策略自由度，也便于判断增益来自跳过坏交易、降低风险，还是改变方向。

基础动量规则及其回看长度必须在当前训练／验证层确定，进入外层测试后固定。不能用外层测试选择“最适合被 Kronos 改进”的基础策略。

6.3 标签应与可执行行为一致

对于固定持有期、独立进入的一笔参考交易，可建立以下净结果标签：

$$y_t^{net} = w_t^{ref} R_{t,t+H}^{exec} - C_{t,t+H}^{fees+slip} - F_{t,t+H}$$

R 按明确的可成交价格口径计算； C 为非负交易摩擦； F 是有符号的资金费用，收取与支付需要区别。未来实际资金费率可用于事后标签与回测结果，但不能泄漏为决策时的输入。

连续组合的换手成本不是参考标签成本乘 a 。最终必须用真实仓位变化重新记账：

$$\Pi_{t+1} = w_t R_{t+1} - c_t \|w_t - w_{t-1}\| - F_{t+1} - S_{t+1}$$

上式是简化的单资产示意。实际费用、滑点、冲击和资金费用按交易与持仓分别计提，避免重复扣费。重叠持有期的标签也不能直接相加为资金曲线。

6.4 损失选择与有限解冻

第一版可以预测净结果或“净结果为正”的概率，再在验证集固定决策阈值。分类胜率不能替代期望收益：高胜率、小盈利、偶发大亏仍可能没有经济价值。若使用 Huber 等稳健损失，需要承认其最优预测量未必等同条件均值，最终仍由组合净表现验收。

冻结读出有希望时，可只解冻最后少数层，再与保持冻结的版本比较；随后才考虑全量微调。保留自回归辅助损失是可试验的正则化手段，但不应预设必须保留。每增加一个损失权重，就增加一项模型选择自由度。

直接优化 Sharpe 或可微组合效用可以作为更后阶段方案。它要求按连续时间构造批次、处理跨批仓位和成本，而不是把任意打乱的单样本当成连续交易轨迹。

6.5 理论边界：门控不能从条件零收益创造 alpha

若在当时全部可用信息下，一条因子的条件毛收益确实为零，则任何仅依赖这些信息的可积门控都不能凭空获得正期望：

$$E[R_{t+1}^f | F_t] = 0 \Rightarrow E[g(F_t) R_{t+1}^f] = 0$$

因此，“不同 regime 抵消”只能作为待检验假说。事后画出趋势期和反转期，不证明这些状态当时可识别。模型可能改善风险分布或减少成本，但那与创造方向信息是不同贡献。

6.6 难度、验收与停止

冻结头约 2/5；有限解冻约 3/5；连续仓位的可微收益优化约 3-4/5。最难的不是网络，而是标签和真实交易过程的一致性。

必须比较原动量、常数缩仓、简单波动目标、普通特征门控和 Kronos 门控。只有回撤变小而收益同步按比例下降，可能只是更少暴露；不能据此称为成功择时。若风险匹配后无增益，停止扩展门控复杂度。

07 波动、下行风险与预测分布

7.1 两条不同路线

风险预测头是一条相对便宜的路线：由历史表征预测未来固定时段的方差、下行分位数或参考策略亏损概率。生成分布路线则保留多条未来路径，估计区间、尾部和策略情景结果。前者不需要多步采样，建议优先。

例如，未来实现方差可定义为：

$$y_t^{RV} = \sum_{j=1}^H r_{t+j}^2$$

需明确这是方差代理，平方根才对应相同口径的波动。收益采样频率、跨缺口处理和交易时段必须固定。下行风险还要说明是持有标的风险，还是执行特定策略后的风险。

7.2 预测风险不等于提取方向收益

先与滞后实现波动、EWMA 以及资源允许时的简单 GARCH 比较。若模型仅改善波动预测，部署价值可以是更稳定的风险预算或更合理的参与程度，但不能直接称为方向 alpha。

验收除风险预测误差外，还要看等风险预算下的组合结果。非线性缩仓可能改变尾部和换手，因此需要同时报告收益、风险、成本和持仓分布。

7.3 必须保留样本路径，而不是从均值路径制造置信区间

当前读取的生成代码在返回前对 `sample_count` 维度取均值。若要做概率研究，需要扩展一个返回所有样本路径的接口，同时保持原接口行为不变。[03]

均值路径的一根 K 线 high/low 不是跨样本预测区间；多条路径平均后的波动也不是预测分布的波动。应分别对每条路径计算收益或方差，再在路径之间统计分位数或期望。

温度和 top-p 会改变模型采样分布。研究未截断模型分布时，以 T=1、top-p=1 为起点；这并不自动使概率正确。偏离这些设置需要在独立验证数据上解释和校准，不能将路径一致率直接称为真实胜率。

7.4 校准与数据要求

分类概率可检查 Brier 分数和可靠性曲线；区间预测检查覆盖率与区间宽度；分位数预测可用 pinball loss；正方差预测可使用预先约定的 QLIKE 形式。所有校准器仅在校准区间拟合，不能先看测试实现值再调整置信水平。

样本路径之间的差异只代表当前生成器表达的分布，不完整反映模型错设、数据缺失和未知市场机制。更多 Monte Carlo 样本降低采样误差，不保证修复分布偏差。

7.5 难度与退出标准

风险头约 2-3/5；开放路径接口约 2/5，但多路径推理和校准的整体成本更高。只有区间更宽、覆盖更高，不足以说明预测更好；必须同时检查锐度和恰当评分。

若始终无法优于简单风险模型，保留代码作为诊断工具即可。合成情景可以用于系统压力测试，但在合成市场里赚钱，不构成真实市场盈利证据。

08 Crypto 原生状态：先做后融合

8.1 为什么比立即扩充 tokenizer 更合适

外部状态可以扩大模型的信息集；重编码相同 OHLCVA 主要改变信息表达。二者有本质差异。但“有经济故事”的外部变量也可能没有可交易增益，因此仍需同任务消融。

第一版把 Kronos 表征和外部状态拼接给小读出器。原 tokenizer 与主干不动。当前输入投影和 Predictor 围绕六通道实现，直接增加列不会自动形成可用的多模态模型。[03]

$$\hat{y}_t = g\left(\left[z_t^{Kronos}, q_t, m_t^{missing}, a_t^{age}\right]\right)$$

missing 表示缺失状态，age 表示该字段距最近可用更新的时长。它们用于区分“真实为零”和“没有信息”。

8.2 分层增加字段

层级	建议候选	主要数据问题
现有价值增强	成交额、成交笔数、可信主动买卖量	字段语义、聚合口径、零值与缺失
合约状态	OI、当时可得 funding 估计、basis、mark-index 差	历史覆盖、发布时间、合约单位
联合市场状态	现货／永续相对流量、跨场所价差	同步时钟、报价币种和延迟
高频／事件状态	LOB、逐笔流、清算消息	数据量、完整性、源间可比性

不要一次接入全部字段。先选能追溯历史、语义稳定、与主要假设直接相关的一组，再扩展。清算消息的记录不能自动当成全市场完整清算量。

8.3 数据可用性常常是主要工程

核验时，Binance USD\$-M 的 OI 历史统计 REST 文档仍注明仅提供最近一个月。这个事实只描述该接口，不代表全部渠道都没有长历史；但不能假设调用它即可补齐几年样本。[11]

每个字段要区分事件时间、实际可用时间和采集时间。资金费率的事前估计、已公告参数和最终结算值不可混用。OI 还需区分合约数量、币本位数量和名义价值，否则价格上涨就可能机械性抬高名义 OI。

缺失数据只能按预先约定的因果规则处理。禁止用未来值反向填充；长时间缺失应触发质量标记或停止使用该分支，而不是无限沿用旧值。

8.4 必须做的四格消融

	无外部状态	有外部状态
无 Kronos	普通特征基线	普通特征 + 状态数据
有 Kronos	普通特征 + Kronos	普通特征 + 状态数据 + Kronos

所有格子使用可比的历史区间。新增字段可能缩短可用历史；不能拿更容易的短时期与困难的长时期比较。最好同时报告共同交集区间和各自完整区间。

工程难度：模型侧约 2／5，数据侧约 2-4／5。若新增数据解释了全部增益，而 Kronos 没有贡献，应保留后融合数据框架、简化模型。

09 Crypto 继续训练与成交密度加权

9.1 继续训练具体要适配什么

继续训练应明确针对标的集合、交易所／产品类型、时间粒度、近期分布或目标相关表征。不能仅用“更多 crypto 数据”作研究假设，因为原模型已经有大量此类预训练样本。[\[01\]](#)

第一轮固定 tokenizer，仅训练自回归骨干；然后用完全相同的下游头和验证方案比较继续训练前后。官方训练脚本已有 tokenizer 与 predictor 分离的结构，因此可以复用接口，但仍需建设自己的时间切分和数据审计。[\[06\]](#)

9.2 推荐实验顺序

先比较冻结原权重与固定 tokenizer 的继续训练；再比较有无少量旧分布回放或温和正则；最后才考虑 tokenizer 适配。每步保持下游任务不变。自回归验证损失下降但下游收益不变，是一种完全可能的结果，不应被掩盖。

抽样至少按资产、时间和产品类别检查。不能让最活跃的大币或最近一段剧烈行情占据全部训练预算；现货和永续也不能因为字段数量一致就不加区分地拼接成一条序列。

超参数由内层验证确定。学习率、训练步数和早停都属于试验自由度；不能根据外层测试收益反复选择 checkpoint。

9.3 特别审计：归一化与自回归训练位置

当前微调数据集使用 lookback 段的统计量归一化整个训练窗口，这是相对于 lookback 末端决策点的合理方向。[\[05\]\[07\]](#)

但若把同一窗口中更早位置的 hidden state 当成“那个早期时点的实时特征”，它可能已使用窗口后部参与计算的统计量。因果 attention 本身不能修复预处理引入的这种时间问题。

对继续训练，需明确“给定完整前缀预测后缀”与“每个位置都代表可交易预测原点”的区别。本方案建议审计后缀损失掩码，或者使用逐原点因果标准化；不能只因整个张量没有显式未来列就认为全部训练位置等价。这个判断是对代码组合的工程审计建议，不是关于原论文训练流程的定论。

9.4 成交密度的三种用法

增加成交活跃度特征，是告诉模型当前活动状态；按活跃度加权损失，是重新分配拟合资源；事件条重采样，是改变时间轴和预测任务。三者要分别测试。

对监督读出器，可先使用只依赖历史信息的温和权重：

$$u_t = \text{clip} \left(\left(\frac{A_t}{EMA_{t-1}(A) + \epsilon} \right)^\gamma, u_{\min}, u_{\max} \right), L = \frac{\sum_t u_t \ell_t}{\sum_t u_t}$$

A 是截至决策时已完成窗口的成交额；也可以另行研究成交笔数，但不能无休止搜索权重形式。权重上下限和 gamma 由内层验证决定。

若权重仅依赖输入，理想无限数据与充分模型容量下，它不会改变真实条件分布；在有限资源下，它改变模型优先学好哪些区域。因而，加权是资源分配假设，不是新增市场信息。

9.5 两个实现陷阱

第一，不能把整个训练窗口末端的活跃度权重无条件应用于更早 token 的预测损失，而又将其描述为每个预测原点都只依赖过去。若训练目标就是按事后活跃事件强调样本，应明确它改变了目标分布，并防止这种权重进入推理信息。

第二，按成交额采样和按成交额加权会叠加，可能重复强调同一批样本。若已经在事件条上近似均衡成交额，再按成交额强加权，也可能无意改变预期目标。

可报告权重集中度及独立加权近似量 $(\sum u)^2 / \sum(u^2)$ ，但这个量不考虑时间自相关，不能当作真实独立交易数。

9.6 难度与停止条件

固定 tokenizer 的继续训练约 2-3/5，算力负担中等；加权损失在现有训练器上的增量较小，整体约 2/5。评估仍在原定交易时钟上进行，不只报告加权验证 loss。

若继续训练仅降低 token loss，或加权收益完全依赖少数高活跃时段，应停止扩大训练规模，先查明分布与目标是否匹配。

10 横截面排序与组合层

10.1 这是替代研究分支，不是必然更优的答案

横截面模型回答同一时刻哪些资产未来相对更强；单资产方向模型回答该资产未来涨跌。两者需要不同标签、取样和组合解释。论文某些 RankIC 结果不能直接作为 crypto 横截面优势的证据。[01]

同一时点分别编码各资产，再训练共享评分头即可做第一版，不必先加入跨资产 attention。配对排序损失可以围绕同一时点、相同持有期的收益差构造：

$$L_{rank} = \sum_{t,i,j} \log \left(1 + \exp \left[-s_{ijt} (v_{it} - v_{jt}) \right] \right)$$

其中 s 是训练标签收益差的符号。应排除或降低极小差值的权重，并限制配对数，以免同一时点的海量相关配对被误认为独立样本。

10.2 币种池、风险暴露与成本

历史币种池必须按当时可交易性和过去流动性定义，包含退市与停止交易的处理。拿今天还活跃的币回测全部历史，会引入生存者偏差。小币种账面排名优势也可能无法按回测价格成交。

先报告普通收益排名；需要“相对 alpha”时，再明确市场、BTC beta、波动和流动性暴露的处理。等美元多空不等于 beta 中性。风险系数必须用历史估计，不能用整个测试期拟合后中性化。

组合约束应包括总杠杆、单资产上限、换手、可成交规模和资金费用。现货场景不能假定可以无限做空；永续场景也要建模保证金、资金费用和可用合约。

10.3 难度与验收

工程约 3/5，数据约 3-4/5。按每个时点计算横截面 IC，并同时报告组合净收益；不能把所有资产与时间混成一个相关系数后忽略市场共同运动。

同一时间块中的全部资产应一起进入 bootstrap 或其他稳健评估单元，保留市场相关性。若增益仅来自高 beta、小币流动性暴露或少数幸存币，应停止宣称独立选币能力。

11 事件时间与双时钟：为什么应当后置

11.1 研究动机

固定时间条压缩了不同密度的市场活动；事件条尝试让每个单位对应一定成交笔数、成交量或成交额。它可能改变序列的可学习性，但不保证每个 token 含有相同信息量，也不保证目标收益更可预测。

建议先从成交额条或成交笔数条选择一种，不要同时搜索大量 imbalance、波动阈值和混合规则。阈值必须由历史确定，不能利用全日或未来平均成交量回头划分历史。

11.2 完整替换时钟的三项困难

未来事件时间未知。 现有 Predictor 接口接收未来时间戳，并在多步生成中使用时间特征；固定时间条的未来时刻已知，成交额阈值条的完成时刻未知。回测时直接提供真实未来事件时间，可能泄漏未来活动速度。[\[03\]](#)

目标和持有期改变。 未来 20 个事件条可能对应很短或很长的真实时间，而仓位占用、资金费用和调仓都在真实时间中发生。不能用“未来 20 条”的成绩直接与“未来 4 小时”比较。

输入分布改变。 固定成交额条的 amount 近似常数，活动速度更多体现在持续时间中。原 tokenizer 学习的通道关系因此发生变化，不能默认原权重等价适用。

11.3 数据工程比表面复杂

只有分钟 OHLCV 不能唯一恢复分钟内的成交顺序和事件边界。严格构建事件条通常需要逐笔或足够细的成交数据，还需处理重复、乱序、丢失、修订和跨日连续性。

事件条有超额成交时，要预先定义大成交是否拆分、超额是否结转。规则会影响 OHLC 与流量统计。报价币种、单位和跨交易所合并也需统一，不能仅按行累加。

11.4 推荐折中：历史事件分支，固定时间决策

在固定调仓时点，取已经完成的历史事件条，构造成交持续时间、价格冲击、买卖不平衡等特征，或用小编码器处理。与原 Kronos 表征后融合，预测相同的固定时间持有期收益。

这样不需要提前知道未来事件的完成时刻，也保留同一交易任务。还应提供一个只含过去活动速度统计、不构建事件序列的廉价对照，检验收益是否只是来自新增持续时间特征。

11.5 升级条件与难度

历史事件辅助分支约 3-4/5；完整事件时间生成、联合持续时间建模或双时钟主干约 4-5/5。只有在固定目标、可比历史覆盖和统一成本下出现稳定增益，才值得升级。

完整方案可以联合预测下一事件的状态与等待时间，也可以取消已知未来时间条件并重训；两者都是新的训练/推理协议。此时应当按新模型研究评估，而不是称为普通 fine-tune。

12 输入重编码、tokenizer 重建与从头训练

12.1 候选表示及其目的

可研究对数收益、蜡烛实体、影线、相对成交量和历史波动归一化。下面是一组候选定义，不是推荐立即全部使用：

$$b_t = \log(C_t/O_t), g_t = \log(O_t/C_{t-1}), u_t = \log[H_t/\max(O_t, C_t)], d_t = \log[\min(O_t, C_t)/L_t]$$

价格必须为正且 OHLC 合法。相对成交量的分母、收益归一化用的波动均仅来自过去。对异常点要先区分坏数据与真实极端行情，不能为了降低 loss 一概删除跳跃。

这些变换改变归纳偏置，但同一原始历史的确定性变换不会凭空增加信息。既可能帮助学习，也可能抹去有用结构。

12.2 为什么六个新通道不能直接冒充原六通道

原 tokenizer 和主干共同形成 token 语义。即使维度保持为六，把收益率放入 open、把 OI 放入 volume，也不能保证预训练关系保留。代码能前向计算，只说明张量形状兼容。^[03]

重新训练 tokenizer 后，相同 token ID 可能代表不同形态。原主干仍可作为初始化，但应比较迁移训练和随机初始化，而不是默认仍享有全部预训练收益。

此外，coarse token 只被结构性损失约束为粗粒度重建，并没有被保证对应“趋势”“拥挤”或某个经济机制。给 token 命名需要额外监督和验证，不能靠目测赋予固定经济意义。

12.3 建议升级阶梯

先做第 5 章的量化前后诊断，再试连续特征旁路/小 adapter；有稳定证据后，才考虑 tokenizer 微调并约束旧 token 语义漂移；最后才是重建 tokenizer 与主干联合适配。

诊断指标包括重建误差、token 使用情况、截断比例、极端区间表现，以及最重要的下游增量。重建更精细或 codebook 更均匀，本身不是经济贡献。

若需要保留生成任务，要定义从新表示重建价格路径的方法与误差传播。若只做判别预测，则不必强行保留完整 K 线生成器；删除无用解码器可能是更好的工程选择。

12.4 从头训练何时合理

从头训练适用于需要明确训练来源、研究新表示/新时钟、或系统比较架构的路线。只为修复对公开权重 cutoff 的疑虑，不必立即从头训练；可先固定具有可验证公开时间的权重，在之后的市场数据上评估。

从头训练还需建立足够强的小模型和随机初始化对照，明确数据预算、计算预算和多随机种子。没有复现 120 亿条级别预训练的必要，也不能把小规模重训失败直接解释为架构无效。

重编码/tokenizer 重建约 4/5，从头整套训练约 4-5/5。没有表示瓶颈证据、没有清晰数据来源或没有训练预算时，不应把这条路线排在前面。

13 神经—符号：受限策略接口，而非无限因子工厂

13.1 合理分工

神经部分处理历史表示或监督概念；符号部分表达透明策略、约束与组合逻辑；回测与统计系统负责检验。神经网络引导符号表达式搜索已有方法研究基础，但这不等于在非平稳金融数据中自动得到可靠规律。

[16]

本方案将“可解释约束”和“自动发现策略”分开。第一版可以只提供透明仓位上限、数据质量门槛与固定动量规则；这已经能与神经预测头组合，不必先引入复杂搜索引擎。

13.2 不把任意 latent 坐标伪装成经济变量

某次训练的 $z[3]$ 不会天然、永久地等于“流动性压力”。不同随机种子或继续训练可能改变坐标。符号层若直接依赖任意坐标，其经济解释和跨版本稳定性都很弱。

更稳妥的是建立小型监督概念接口，例如固定持有期的波动预测、策略净结果预测、数据陈旧程度、经过校准的下行概率。概念必须有定义和验证；这些输出仍可能错，不能被当成市场事实。

用未来实现情况作训练标签是允许的，但部署输入只能是当时产生的预测。符号搜索使用概念预测时，应采用 out-of-fold / walk-forward 预测，不能用上游模型在同一训练样本上的过拟合预测来评价策略。

13.3 最小 DSL 和安全边界

可先允许 rank、zscore、lag、clip、加减乘、带保护的除法和少量条件门控。限制表达式深度、窗口集合、常数数量和最大换手；禁止负 lag、全样本统计、任意文件访问及未登记外部数据。

符号系统输出的应当是结构化表达式树，而不是不受约束的任意 Python。执行前进行类型、时序和复杂度检查。仓位 / 杠杆上限由独立组合层执行，不把安全约束只写在提示词里。

研究优先级可以用一个透明的多目标准则组织，而非盲目最大化单次 Sharpe：

$$J = \text{validated utility} - \lambda_1 \text{ complexity} - \lambda_2 \text{ turnover} - \lambda_3 \text{ instability}$$

该式是设计模板，不是已经校准的万能 fitness。更推荐先用硬门槛筛掉不合规候选，再在有限候选中比较稳健效用。

13.4 LLM agent 应当承担什么

LLM 适合提出可检验假设、生成受限表达式、解释失败并管理实验。但它不能凭文字判断收益是否真实，也不能把测试集当成反复修改的反馈环境。每个候选记录来源、父表达式、参数、使用数据与被否定原因。

外层锁定测试必须与生成 / 修改代理隔离。实验编排工具默认研究权限；实盘权限、资金操作和交易所写入与研究系统分开。LLM 不负责批准自己的候选进入实盘。

13.5 难度与验收

受限规则层约 2-3 / 5；完整群体搜索、学习引导和实验治理约 4-5 / 5。最大的风险是多重尝试和对反馈集的适应，而非表达式计算速度。[15]

只有普通模型和简单规则已经给出可重复增益，自动搜索才值得接入。若规则对随机种子、微小成本变化或某一时间段极度敏感，应淘汰，而不是用更复杂解释维护它。

14 数据、时间切分与验证规范

14.1 四个时间必须区分

每条记录至少管理事件时间、可用时间、采集时间和版本／修订信息。每个训练标签另有结束时间。交易决策时只能使用可用时间不晚于决策时点的版本。

K 线常以开盘时间标记，完整 OHLCV 却在结束后才可得。接口还可能使用统计区间的开始或结束时间。统一存储 UTC，同时保留原口径；不要靠简单相同时间戳 join 就假定同步。

历史修订数据不能被自动视为当时可得。没有 point-in-time 版本的数据，应明确限制并进行保守延迟／缺失敏感性分析，不能把猜测的历史可用时间写成事实。

14.2 外层 walk-forward 与内层模型选择

外层按整段时间滚动，所有资产共享边界；只在过去训练，在后续区间测试。内层验证用于超参数、门控阈值、校准器和 checkpoint 选择。每个阶段都保留从未进入选择过程的最终锁定测试，后续再增加前瞻纸面记录。

训练标签若跨入验证／测试窗口，应从训练集中清除。边界间隔与最长目标持有期、标签重叠和数据延迟匹配，不采用一个没有解释的固定“神奇天数”。回看窗口使用过去历史本身不等于泄漏；关键在于是否用到了该预测原点之后才可得的信息。

不要随机把同一市场时刻的不同币种分散到训练和测试后称为时间外推。资产外推可作为额外实验，但不能代替时间外推。

14.3 预训练污染与时间可部署性的区别

论文声称的 cutoff、公开文件的最早出现时间和具体 checkpoint 的训练来源是三类证据。[\[01\]\[08\]](#)

固定一个已经公开、校验值确定的模型文件，再使用其公开之后发生的市场数据，可建立重要的时间隔离。但模型选择、数据修订和反复使用这段测试数据仍会污染评价。不能只锁模型而不锁全部实验过程。

另外，某模型尚未发布时的历史回测，即使训练数据截止更早，也不等于当时实际可以部署。报告应区分“历史解释性实验”和“严格模拟当时可取得全部工具的交易实验”。

14.4 因果一致性测试清单

测试	做法	不通过意味着什么
截断一致性	全文件运行与截止 t 的文件运行比较 t 信号	预处理／策略可能使用后部数据
未来扰动	随机修改 t 之后数据，t 结果应不变	隐性未来依赖
可用时间断言	检查每个输入 available_at ≤ decision_at	对齐或字段定义错误
训练来源断言	训练／校准标签结束时间早于允许边界	fold 或 checkpoint 混用
缓存重算一致性	抽样比较缓存与独立重算	缓存键不足或版本污染
批处理一致性	单样本与批量、不同合法 padding 对比	掩码、批维或推理模式问题
执行时序	确认信号可用后才允许成交	同根收盘／开盘的时序偷看
滚动指标稳定性	比较不同足够长历史启动长度	递归指标未收敛或历史不足

Freqtrade 的 lookahead-analysis 与 recursive-analysis 有助于检查策略层，但它们不能证明外部模型、训练数据、上游缓存和 checkpoint 来源全部无泄漏。通过这些命令只是审计的一部分。[\[12\]](#)[\[13\]](#)

14.5 统计单位和报告口径

单期收益、重叠持有期标签和同时刻多资产并非大量独立证据。评估模型差异时，按共同时间块对各模型的组合收益一起重采样，保留时序与横截面结构；块长应做预先得定的敏感性检查。

同时报告预测和经济指标：损失／校准、样本外净收益、波动与回撤、换手、资金费用、容量假设、收益集中度、各折结果及配对差异区间。收益曲线更平滑不自动意味着均值更高。

对策略搜索保留全部尝试，必要时使用 Deflated Sharpe Ratio 等选择偏差诊断。其结果依赖试验相关性、有效尝试数和分布假设；不能把一个修正统计量当作盈利保证，也不能替代前瞻验证。[\[15\]](#)

14.6 交易成本、成交与幸存者偏差

手续费至少包含双边成本；滑点与冲击按交易类型和规模明确；资金费用按持仓和结算记账。maker 订单不能一概假设全部成交且无不利选择。K 线级回测对根内价格顺序、队列与流动性存在局限，需做保守假设或细粒度回放。[\[14\]](#)

可预先设置基准、提高费用／滑点、增加执行延迟等压力情景。提高倍数是研究假设，不是对真实最坏情况的精确描述。历史币种池应保留上市、退市、停牌、交易对转换和缺失状态。

最终通过标准应在研究前定义最小经济贡献与成本容忍度，不必要求一个机械的 p 值门槛。若置信区间仍很宽，结论应是证据不足，而不是自动认定无效或有效。

15 工程分层、资源预算与 Freqtrade 接入

15.1 建议目录与职责

kronos_lab/	
configs/	# 数据、模型、成本、切分、实验预算
data_contracts/	# 时间、单位、版本与可用性规则
features/	# 纯因果价量特征与状态对齐
encoders/	# Kronos 适配器与表征诊断
heads/	# 收益、参与度、风险、排序
training/	# 固定折训练、校准、checkpoint 管理
evaluation/	# 配对对照、成本压力、统计报告
adapters/	# Freqtrade 预测文件与策略接口
registry/	# 试验来源、失败记录、晋级状态
tests/	# 因果、缓存、批量与执行时序测试

这是建议结构，不是声称现有仓库已经提供这些模块。尽量将修改封装在薄适配层中，少量必要补丁固定在独立分支，避免直接把研究逻辑散落到上游模型文件里。

15.2 研究层与交易回放层分离

研究层完成数据对齐、训练、表征提取和每折样本外预测；Freqtrade 接收已带来源信息的预测，执行一致策略和交易回放。第一版不在每次策略回测内部重新训练模型。

现有 `/home/athena/ft_userdata` 作为接入目标，先使用隔离的策略名、配置副本和输出路径。保留原数据与配置，不覆盖用户已有策略。接入时明确 Freqtrade candle 的日期口径和实际成交时点，以可用时间而非“看起来相同的 date”连接预测。

外部预测读取应有最大陈旧时长；缺失或过期时进入预定安全状态，例如不开新仓。关闭状态与保留旧仓的行为需要分别定义，不能让数据缺失隐式变成反向信号。

15.3 两种不同的缓存

表征缓存以资产、历史窗口、模型／tokenizer 版本、标准化和数据快照为键。冻结模型且完全相同窗口时可复用；只改变读出器可以不重新跑骨干。

预测缓存还必须包含读出器、校准器、fold、训练与验证边界。不能用在较晚数据上训练的模型回头生成早期“样本外”信号；也不能用最新模型重新计算旧折后覆盖历史预测。

缓存文件采用不可变输出与内容校验，实验注册表只引用这些文件。同一字段定义变更应升级 `schema_version`，而不是原地改写后继续沿用旧结果。

15.4 8GB 显存条件下的建议

先以 Kronos-small 冻结推理、短批量、固定上下文完成性能基准；记录预热后吞吐与峰值显存。随后再测试末层解冻和全量微调。24.7M 参数并不意味着必须使用 LoRA，也不保证任何 batch 都能运行。[\[09\]](#)

优先削减重复骨干计算和无用多路径生成，再考虑混合精度、梯度累积与检查点技术。改变数值精度后要重做一致性测试。CPU 服务器可承担数据整理、特征、回测和报告，GPU 主要承担编码与训练；具体安排依实测而定。

不要提前把大规模 KV cache 工程列为 P0。冻结末端表征只需历史前向；滚动标准化或滑窗变化还可能使跨窗口缓存失去等价性。任何推理加速都要与参考实现做数值和任务结果对照。

15.5 应有的工件清单

每次实验至少保存配置快照、依赖版本、代码提交、数据 manifest、权重校验、切分定义、训练日志、原始样本外预测、组合流水、指标和失败原因。报告必须能从这些不可变工件重建。

对完整研究系统，工程验收首先是“重跑得到同一结论、任意信号可追溯”，而不是“界面显示漂亮的预测图”。

16 分阶段执行、晋级与停止条件

16.1 推荐里程碑

阶段	最小工作	必须交付	晋级条件
M0：可信基座	固定数据契约、时序、成本、基线和版本	审计测试与基线流水	关键泄漏测试通过
M1：表征价值	冻结表征、简单／小非线性读出、随机骨干对照	配对样本外结果	出现可重复增量或明确诊断
M2：任务适配	固定动量门控；或风险／排序替代任务	风险匹配、净成本结果	增益不是单纯缩仓或暴露
M3：信息与分布	可靠状态后融合、继续训练、温和加权	四格消融与前后比较	增益来源可识别
M4：结构改造	事件辅助、量化诊断驱动的 tokenizer 改造	同任务、同信息对照	低成本版本无法解释增益
M5：受限搜索	概念接口、有限符号搜索、试验治理	全候选记录与锁定测试	简单系统已稳定且可追溯
M6：前瞻观察	冻结候选、纸面运行、成本与失效监控	时间戳化预测与执行偏差	另行决定是否进入资金测试

这些不是承诺全部完成的线性项目。阶段可以停止，也可以转向不使用 Kronos 的更简单方案。

16.2 首轮实验矩阵

建议先锁一个主要任务，再运行下列最小实验。各实验共享币种池、预测时点和成本；下游头使用同等预算。只有上一组给出清楚结果，才扩展下一组。

ID	实验	唯一主要变化	需要避免的误读
E00	固定动量／普通特征基线	无 Kronos	不把市场上涨当模型收益
E01	基线 + 冻结 Kronos	加预训练表征	不同时增加大预测头
E02	基线 + 随机冻结骨干	移除主干预训练	tokenizer 仍可能已预训练
E03	量化前／后探针	表征阶段不同	控制维度与正则化预算
E04	固定动量 + 参与头	改为策略参与任务	与常数缩仓／波动目标比较
E05	外部状态四格消融	只改变信息源	统一共同历史覆盖
E06	crypto 继续训练	骨干训练分布	下游头与目标不变
E07	温和活跃度加权	样本权重	仍在原交易时钟验收

风险预测和横截面排序可以替代 E04 成为主任务，不建议第一轮同时把所有标签都作为“总会有一个成功”的搜索空间。

16.3 停止规则应该如何写

表征路线停止： 在预定读出器、有限解冻和合理样本范围内，Kronos 相对普通特征没有稳定增量；不再以无限增大模型来解释失败。

继续训练停止： token loss 改善未转化为主要任务改善，或增益无法跨折保持；回到任务定义，而不是继续无上限追加语料。

数据分支停止： 增益来自字段时间错配、过短历史或事后修订；不能用更复杂模型补救不可追溯数据。

复杂架构停止： 事件时间、重 tokenizer 或符号搜索的收益可被简单活动度特征、风险缩放或已有状态数据解释；优先保留简单版本。

证据不足时： 明确记录结论和最有价值的下一批数据。样本不足不是研究失败，但不允许升级为实盘有效性声明。

16.4 最终建议

第一版只回答一个问题：在可执行的固定时间任务上，Kronos-small 的历史表示是否比普通特征提供稳定增量。若有，优先转成动量参与、风险或排序头；若没有，先检查数据和目标，再决定是否值得适配预训练。

完整神经一符号系统应当建立在这些证据之上，而不是用它绕过证据。最值得保留的研究成果，可能是改进后的 Kronos，也可能是一套揭示“Kronos 在此任务上并不必要”的可靠实验系统。

附录 A 接口、配置与审计模板

A.1 样本与预测记录契约

字段组	建议字段	必须满足的关系
身份	venue、instrument、product、timeframe	标的与产品语义稳定
时间	bar_open_at、bar_close_at、available_at、decision_at	完成和可用均不晚于决策
输入来源	snapshot_id、schema_version、feature_version	可追溯原始与变换版本
模型来源	tokenizer_revision、model_revision、head_id、calibrator_id	指向不可变工件
训练边界	fold_id、fit_end、calibration_end、label_end_max	不跨入允许的测试边界
预测输出	target_name、horizon、score、quality_flag、valid_until	标签和有效期明确

预测输出不应含未来实现值。未来实现值放入独立评估表，避免策略或研究代理在读信号时意外接触标签。

A.2 表征接口示意

下面是拟议接口的职责示意，不是已经运行验证的完整实现。真正实现需加上数据契约、版本加载和设备处理。

```
# history 只包含 decision_at 时已经可用的已完成 K 线。
# model 和 tokenizer 已固定 revision，并显式设为 eval。
# 每个预测原点独立构造、标准化窗口；不得混用全历史统计量。
x, stamp = prepare_causal_window(history, config)
with torch.inference_mode():
    s1, s2 = tokenizer.encode(x, half=True)
    _, context = model.decode_s1(s1, s2, stamp)
    z = context[:, -1, :] # 等长、无尾部 padding 的情形
# 有 padding 时应选择各样本最后一个有效位置。
# z 的缓存键包含窗口、标准化和所有模型／数据版本。
```

正式实现应验证单样本和批处理一致性，并补齐输入校验、设备／精度设置及异常处理。读取 context 是现有代码能力；prepare_causal_window 是需要自行开发的接口。[03]

A.3 首轮配置示例

```
# 研究起点；非现有 CLI，非经验证最优参数。
experiment:
  primary_task: momentum_participation
  outer_split: walk_forward
  final_holdout: locked
  register_all_trials: true
model:
  name: Kronos-small
  repository_commit: 67b630e67f6a18c9e9be918d9b4337c960db1e9a
  model_revision: REQUIRED
  tokenizer_revision: REQUIRED
  freeze_backbone: true
  freeze_tokenizer: true
  lookback: 256
  representation: last_valid_hidden
  seed_set: [17, 29, 43]
data:
  timeframe: 1h
  target_horizonBars: 4
  universe_rule: point_in_time_liquidity
  availability_join: backward_asof
  max_staleness: REQUIRED_PER_FIELD
execution:
  earliest_fill: after_signal_available
  fee_schedule: REQUIRED
  slippage_model: REQUIRED
  funding_accounting: signed_by_position
```

示例中的 1h、4 根、256 根和随机种子只用于给工程提供完整形状。任何更换都应登记；不能在看完锁定测试后把它改成更漂亮的组合。REQUIRED 项未填时，系统应拒绝正式评估。

A.4 一页式实验结论模板

每个实验记录：假设与经济理由；相对基线的唯一改动；代码／数据／权重版本；训练、验证、校准、测试区间；全部尝试数；主要与次要指标；成本压力；收益集中度；失败测试；结论；晋级或停止理由。

结论只使用“支持继续研究”“未见增量”“证据不足”“因审计问题无效”等明确措辞。不要用“模型理解了市场”“发现稳定机制”代替可复核结果。

附录 B 术语与解释边界

术语	本文含义	不能自动推出什么
表征／representation	从历史输入提取的向量	已获得新信息或经济理解
Alpha／增量收益	在指定基准、风险与成本口径下的贡献	某段绝对赚钱就有 alpha
Regime／市场状态	可定义或预测的条件状态	事后可区分就能事前择时
DAPT／继续预训练	在领域语料上继续优化预训练目标	token loss 下降就能盈利
Probe／探针	在固定表示上训练小读出器	线性失败等于完全无信息
Calibration／校准	预测概率／区间与实现频率一致性	校准正确就有交易优势
Event time／事件时间	按活动阈值而非等时长分段	每条事件包含相同信息量
Point-in-time	使用当时可得的数据版本	当前历史文件天然满足要求
OOS／样本外	未参与当前训练与选择的评估区间	反复用于调参仍是有效 OOS
Neuro-symbolic	神经表示与可执行符号规则结合	因果性、可解释性或收益保证

本方案不主张传统机器学习必然浅显，也不主张市场有效性使所有研究无意义。它主张把“信息是否存在”“模型是否读取到”“收益是否可执行”分别验证，避免用更复杂的架构代替问题定义。

参考资料与核验范围

本文主要依据原论文、作者仓库、官方模型卡、交易所与 Freqtrade 官方文档。参考编号对应具体事实或实现接口；难度、优先级、实验矩阵与停止规则是本方案的建议，不是来源已经证实的结论。网页和 API 文档核验日期为 2026-10-07，实施时仍应按固定版本重新确认。

[01] Shi, Y. et al. Kronos: A Foundation Model for the Language of Financial Markets. arXiv:2508.02739v1, 2025. 重点核验附录 C、D、数据表与指标定义。 [原始来源 ↗](#)

[02] shiyu-coder/Kronos, 作者仓库与固定代码快照。本文引用提交 67b630e67f6a18c9e9be918d9b4337c960db1e9a。 [原始来源 ↗](#)

[03] Kronos, model/kronos.py。编码器、decode_s1、Predictor、采样聚合和标准化实现。 [原始来源 ↗](#)

[04] Kronos, model/module.py。时序嵌入、attention、分层嵌入与损失接口。 [原始来源 ↗](#)

[05] Kronos, finetune/dataset.py。公开微调窗口构建与标准化。 [原始来源 ↗](#)

[06] Kronos, finetune/train_predictor.py。tokenizer 与 predictor 分离的训练流程。 [原始来源 ↗](#)

[07] Kronos PR #234, Fix data leakage in normalization window (#227)。证据范围限于该公开微调补丁。 [原始来源 ↗](#)

[08] Kronos Issue #265, Clarification on training data temporal range (cutoff date) for Kronos-base。用于记录 checkpoint 来源澄清需求，不把评论者推断当作作者结论。 [原始来源 ↗](#)

[09] NeoQuasar/Kronos-small, 官方模型卡及模型规格。 [原始来源 ↗](#)

[10] Lim, B., Zohren, S., Roberts, S. Enhancing Time Series Momentum Strategies Using Deep Neural Networks. arXiv:1904.04912。方法背景，不作为本方案 crypto 收益证据。 [原始来源 ↗](#)

[11] Binance Developer Documentation, USDⓈ-M Futures, Open Interest Statistics。核验历史覆盖、字段与统计时间说明。 [原始来源 ↗](#)

[12] Freqtrade Documentation, Lookahead analysis。 [原始来源 ↗](#)

[13] Freqtrade Documentation, Recursive analysis。 [原始来源 ↗](#)

[14] Freqtrade Documentation, Backtesting。用于确认回测假设与限制；上线前另需交易所级执行核验。 [原始来源 ↗](#)

[15] Bailey, D. H., López de Prado, M. The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting and Non-Normality. 作者公开稿。 [原始来源 ↗](#)

[16] Petersen, B. K. et al. Deep symbolic regression: Recovering mathematical expressions from data via risk-seeking policy gradients. arXiv:1912.04871。用于神经引导符号搜索的方法背景。 [原始来源 ↗](#)

文档结语：先验证权重的增量价值，再改变训练分布；先改变决策目标，再改变 token 语义；先证明一个模块有用，再组合多个模块。